Sistemas Inteligentes

Profa. Dra. Nathalia da Cruz Alves

Introdução à IA Conexionista

Oferecer ao aluno uma introdução à abordagem da IA conexionista, descrevendo características de funcionamento, formas de aprendizado, modelos de redes neurais e aplicações típicas.

As Abordagens da Inteligência Artificial

IA Simbólica

Contexto: Inteligência era geralmente associada a uma característica unicamente humana, de representação de conhecimentos e resolução de problemas, refletindo um ponto de vista altamente antropocêntrico.

Hipótese: Um sistema simbólico é capaz de manifestar um comportamento inteligente. Exemplo: Sistema de Símbolos Físicos (Newell & Simon)

As Abordagens da Inteligência Artificial

IA Conexionista

Contexto: Existe uma série de tarefas que os seres vivos, e os seres humanos em particular, parecem resolver de maneira inata: o processamento de imagens, o reconhecimento da fala, a recuperação de informações de maneira associativa, a filtragem adaptativa de sinais, o aprendizado de novos fatos e ideias, etc.

Hipótese: Se for construído um modelo suficientemente preciso do cérebro, este modelo apresentará um comportamento inteligente. Se apenas uma pequena parte do cérebro for reproduzida, a função exercida por esta parte emergirá do modelo.

As Abordagens da Inteligência Artificial

IA Simbólica:

- Conhecimento representado por **regras** (ou estruturas similares), facilmente tratáveis e analisáveis
- Permite a explicação do processo que levou a uma determinada resposta
- Fácil inserção de novos conhecimentos obtidos a partir do especialista ou por meio de métodos automáticos de aquisição de conhecimento

IA Conexionista:

- Conhecimento representado por **exemplos** (casos resolvidos)
- Dificuldade de explicar todos os conhecimentos relativos ao problema por meio de regras simbólicas
- A inserção de novos exemplos pode exigir novo treinamento da rede
- São capazes de generalizar o seu conhecimento a partir de exemplos anteriores

IA Simbólica

Operação Lógica E (*AND*)

```
AND(A,B) =
    if A = 0:
        AND = 0
    else if B = 0:
        AND = 0
    else:
        AND = 1
```

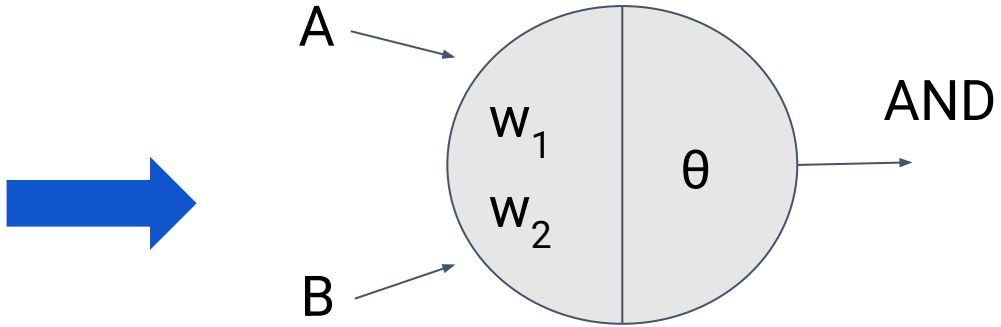


A	B	AND
0	0	0
0	1	0
1	0	0
1	1	1

IA Conexionista

Operação Lógica E (*AND*)

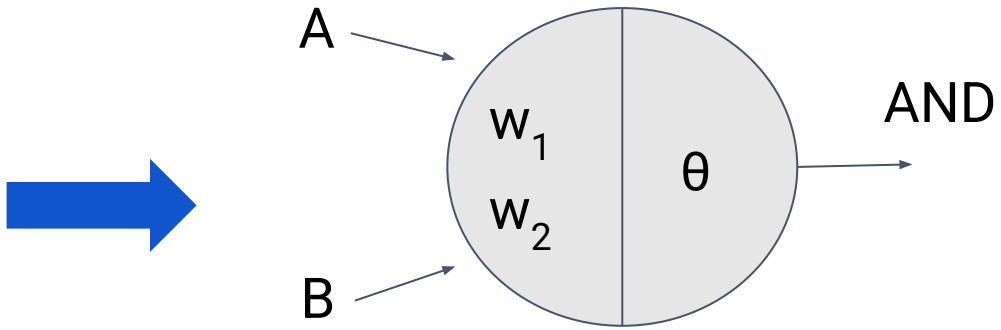
A	B	AND
0	0	0
0	1	0
1	0	0
1	1	1



IA Conexionista

Operação Lógica E (*AND*)

A	B	AND
0	0	0
0	1	0
1	0	0
1	1	1



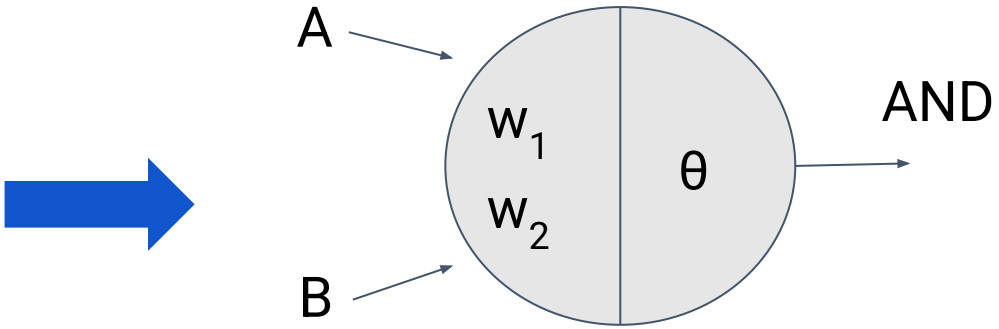
$A.w_1 + B.w_2 \geq \theta$

w_1 = ?
w_2 = ?
θ = ?

IA Conexionista

Operação Lógica E (*AND*)

A	B	AND
0	0	0
0	1	0
1	0	0
1	1	1



$$A.w_1 + B.w_2 \geq \theta$$

$w_1 = 1$
$w_2 = 1$
$\theta = 2$

Fundamentos Biológicos da IA Conexionista

O Cérebro

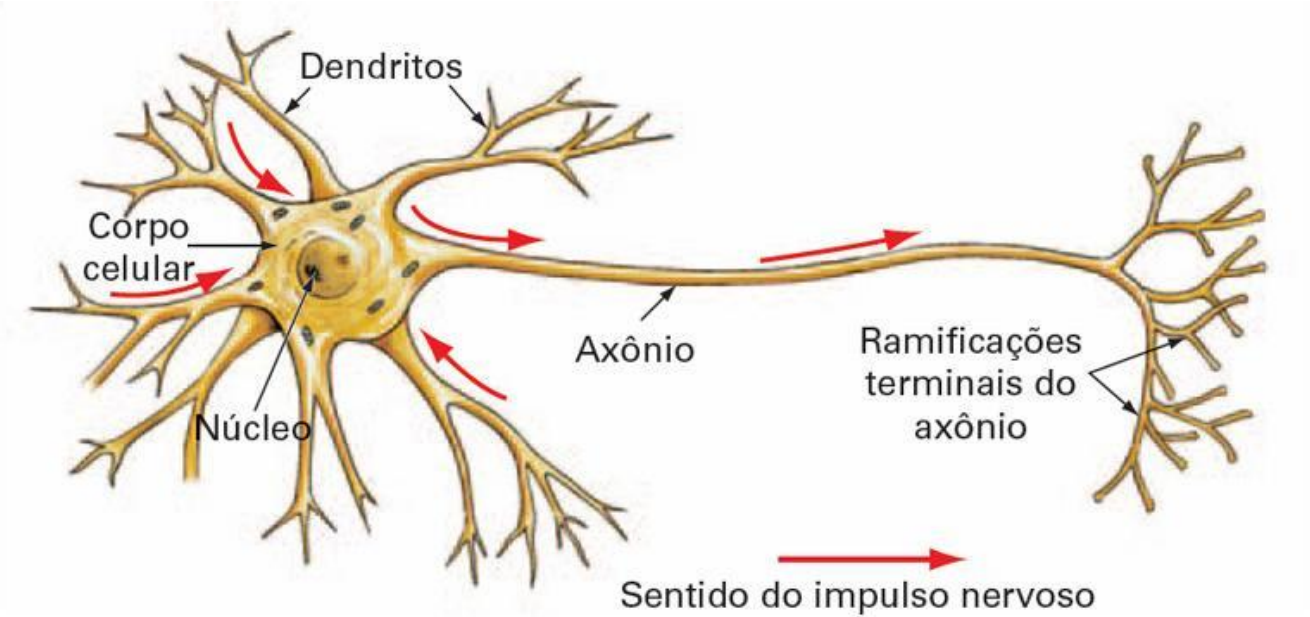
- Composto por neurônios
  (10^5 na mosca da fruta, $5x10^6$ no rato e 10^{11} no ser humano)

O Cérebro Humano

- O cérebro humano tem ~ 10 bilhões de **neurônios**
  - Cada neurônio tem ~ 1.000 a 10.000 conexões
    - 60 trilhões de conexões - 10^{14} sinapses
- Massa: 1-2kg no adulto - 2% do peso
  - 20% do peso do recém-nascido
- Usa 20% do oxigênio, 25% da glucose, 15% do fluxo de sangue

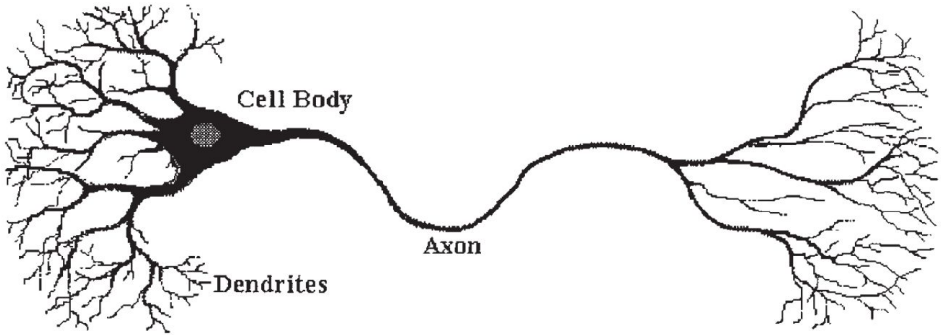
Fundamentos Biológicos da IA Conexionista

O Neurônio

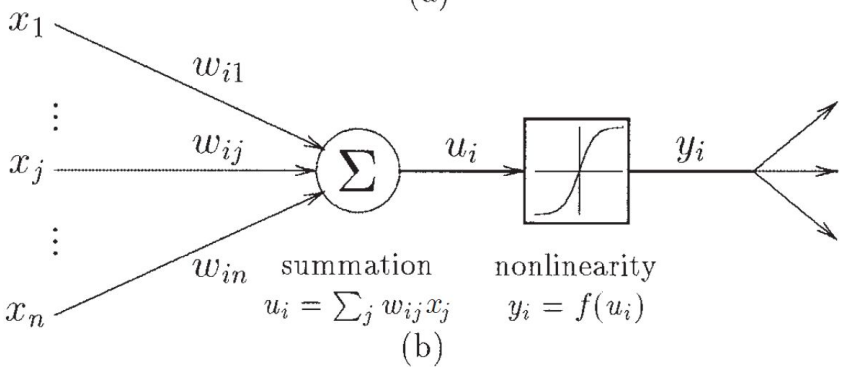


Fundamentos Biológicos da IA Conexionista

O Neurônio para Redes Neurais



Neurônio biológico



Neurônio artificial

Redes Neurais

DEFINIÇÃO

Redes Neurais Artificiais são sistemas inspirados nos neurônios biológicos e na estrutura massivamente paralela do cérebro com capacidade de adquirir, armazenar e utilizar conhecimento experimental

Estrutura geral:

- Sistemas compostos de diversas unidades simples (neurônios artificiais) que, conectadas adequadamente, podem gerar comportamentos complexos
- Comportamento é determinado pela estrutura das ligações (topologia) e pelos valores das conexões (pesos sinápticos)

Modelos de Neurônios Artificiais

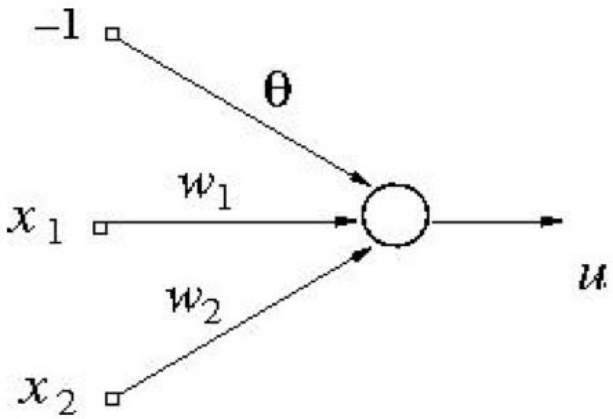
Evolução Histórica

- **McCulloch & Pitts (1943)**
  - Modelo computacional para o neurônio artificial
  - Não possuía capacidade de aprendizagem

- **Hebb (1949)**
  - Modelo de aprendizado (*Hebbian Learning Rule*)

- **Rosenblatt (1957)**
  - Modelo Perceptron, com grande sucesso em certas aplicações e problemas em outras aparentemente similares

Neurônio Artificial - McCulloch e Pitts



x_1, x_2: entradas

w_1, w_2: pesos sinápticos

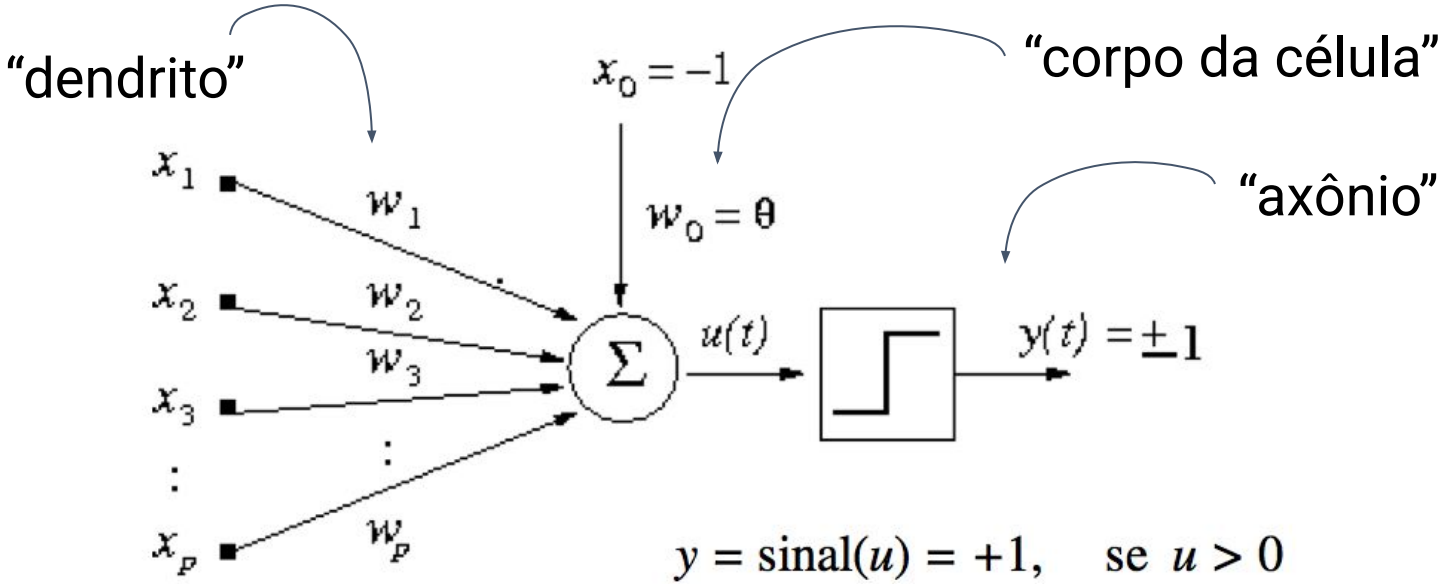
θ: limiar (*bias*)

u : ativação

A ativação (u) do neurônio é dada por:

$$u = w_1x_1 + w_2x_2 - \theta$$

Neurônio Artificial - McCulloch e Pitts



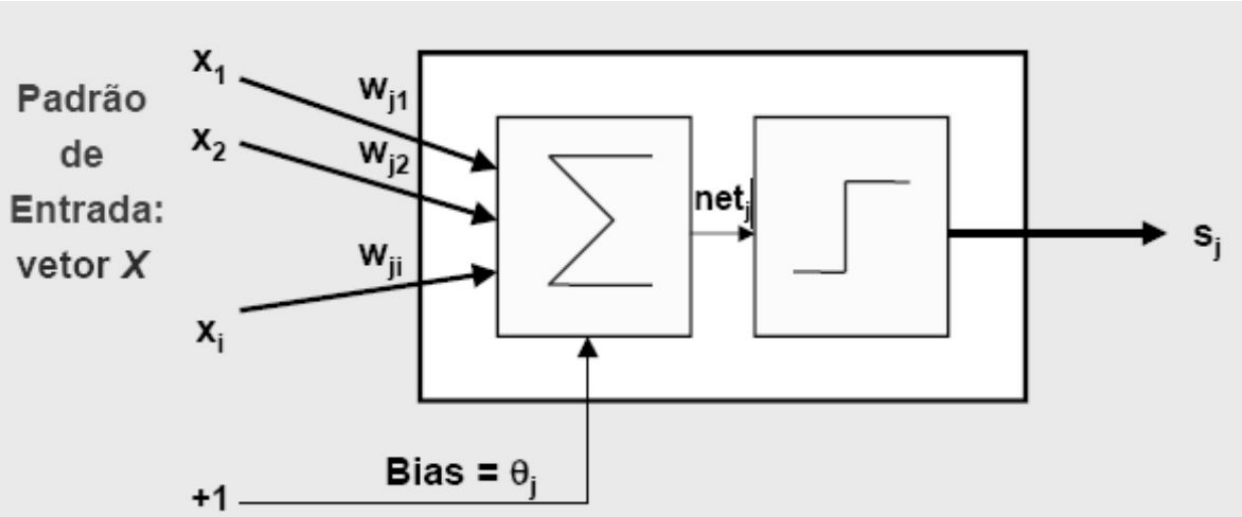
$y = \text{sinal}(u) = +1, \quad \text{se } u > 0$

$y = \text{sinal}(u) = -1, \quad \text{caso contrário.}$

Aplicação inicial: Classificação

PERCEPTRON (Rosenblatt, 1957)

Na sua forma mais simples o modelo perceptron consiste de:



Regra de Propagação
$net_j = \Sigma x_i.w_{ji} + \theta_j$

Função de Ativação
Degrau

Topologia
Uma única camada de processadores

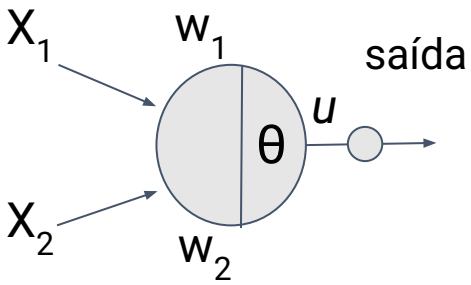
Algoritmo de aprendizado
Supervisionado

Valores de entrada/saída:
Binários

Aplicação inicial: Classificação

PERCEPTRON (Rosenblatt, 1957)

entradas



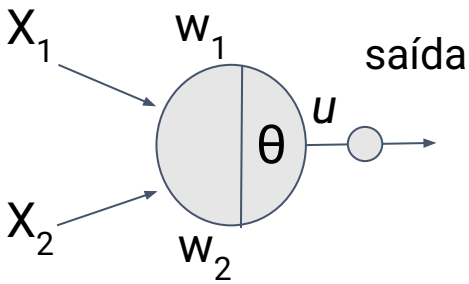
$u = x_1.w_1 + x_2.w_2 + x_0.\theta$

saída = $f(u) = \begin{cases} 1, \text{ se } u > 0 \\ 0, \text{ se } u \leq 0 \end{cases}$

Aplicação inicial: Classificação

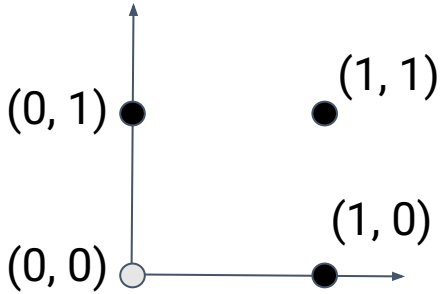
PERCEPTRON (Rosenblatt, 1957)

entradas



saída = $f(u) = \begin{cases} 1, \text{ se } u > 0 \\ 0, \text{ se } u \leq 0 \end{cases}$

$u = x_1.w_1 + x_2.w_2 + x_0.\theta$

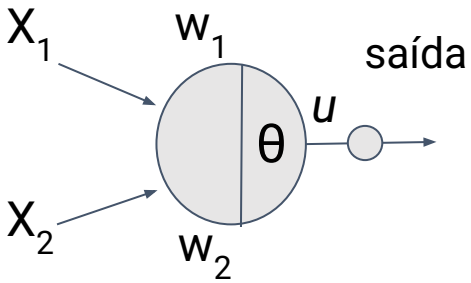


Determine w_1, w_2 e θ para que o Perceptron aprenda a função lógica **OU**

Aplicação inicial: Classificação

PERCEPTRON (Rosenblatt, 1957)

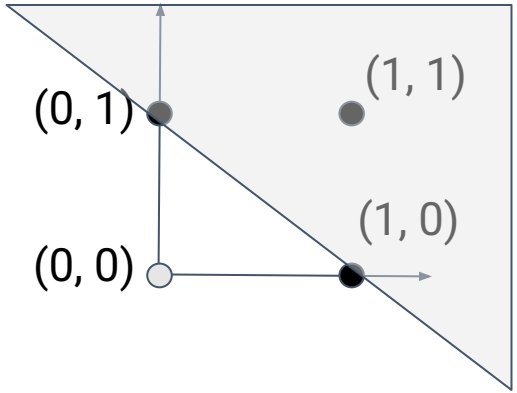
entradas



saída = $f(u) = \begin{cases} 1, \text{ se } u > 0 \\ 0, \text{ se } u \leq 0 \end{cases}$

$u = x_1.w_1 + x_2.w_2 + x_0.\theta$

Determine w_1, w_2 e θ para que o Perceptron aprenda a função lógica **OU**



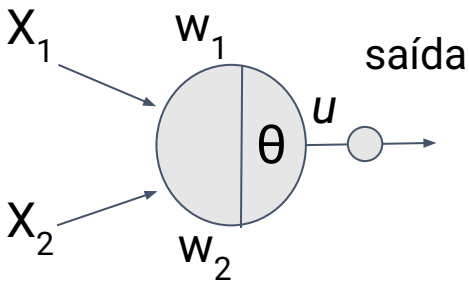
Possível solução:

$w_1 = 1$
$w_2 = 1$
$\theta = 0$

Aplicação inicial: Classificação

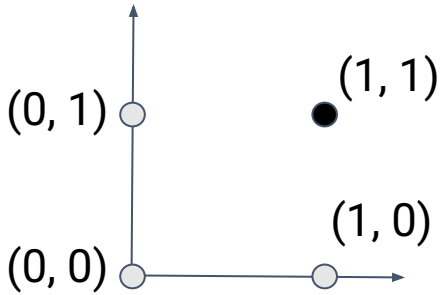
PERCEPTRON (Rosenblatt, 1957)

entradas



saída = $f(u) = \begin{cases} 1, \text{ se } u > 0 \\ 0, \text{ se } u \leq 0 \end{cases}$

$u = x_1.w_1 + x_2.w_2 + x_0.\theta$

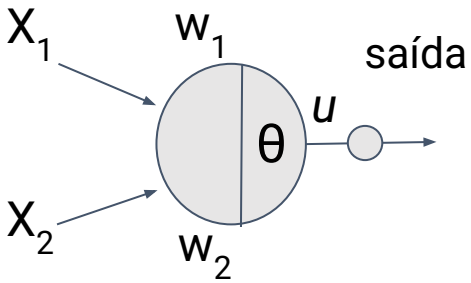


Determine w_1, w_2 e θ para que o Perceptron aprenda a função lógica **E**

Aplicação inicial: Classificação

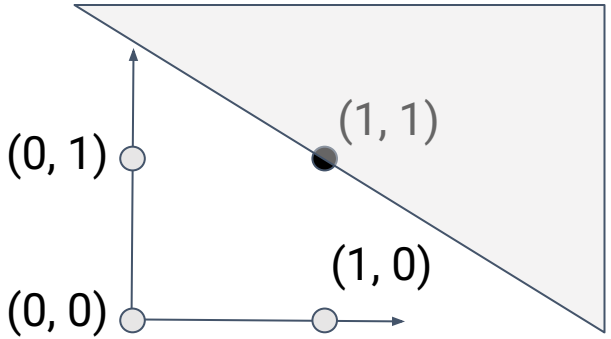
PERCEPTRON (Rosenblatt, 1957)

entradas



$u = x_1.w_1 + x_2.w_2 + x_0.\theta$

saída = $f(u) = \begin{cases} 1, \text{ se } u > 0 \\ 0, \text{ se } u \leq 0 \end{cases}$



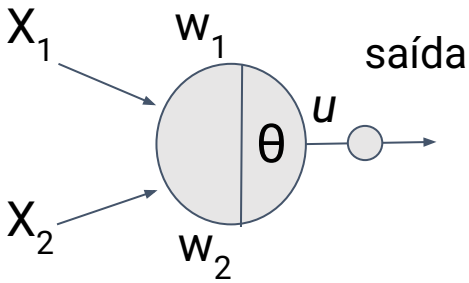
Possível solução:
$w_1 = 1$
$w_2 = 1$
$\theta = -1{,}5$ *
*corrigido

Determine w_1, w_2 e θ para que o Perceptron aprenda a função lógica **E**

Aplicação inicial: Classificação

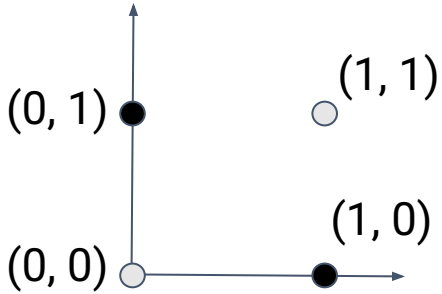
PERCEPTRON (Rosenblatt, 1957)

entradas



saída = $f(u) = \begin{cases} 1, \text{ se } u > 0 \\ 0, \text{ se } u \leq 0 \end{cases}$

$u = x_1.w_1 + x_2.w_2 + x_0.\theta$

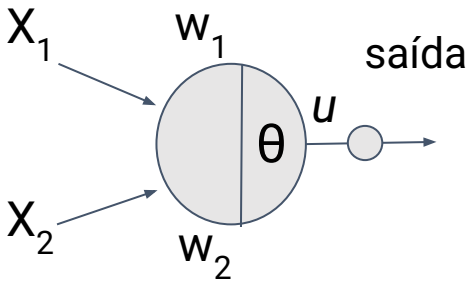


Determine w_1, w_2 e θ para que o Perceptron aprenda a função lógica **OU-EXCLUSIVO (XOR)**

Aplicação inicial: Classificação

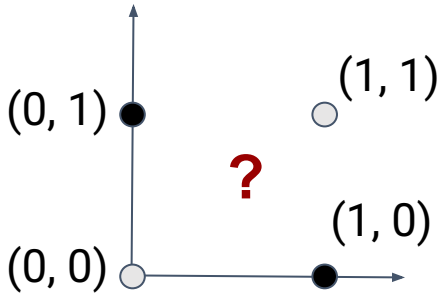
PERCEPTRON (Rosenblatt, 1957)

entradas



saída = $f(u) = \begin{cases} 1, \text{ se } u > 0 \\ 0, \text{ se } u \leq 0 \end{cases}$

$u = x_1.w_1 + x_2.w_2 + x_0.\theta$

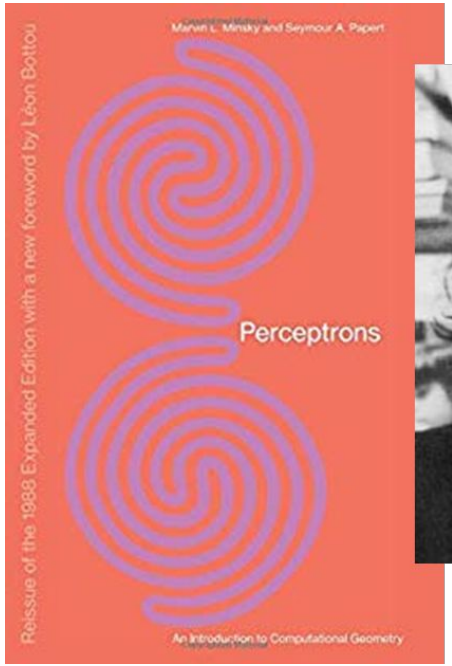


Determine w_1, w_2 e θ para que o Perceptron aprenda a função lógica **OU-EXCLUSIVO (XOR)**

O Perceptron é capaz de distinguir **apenas padrões linearmente separáveis**

Perceptrons

Marvin Minsky & Seymour Papert (1968)





Perceptrons

Marvin Minsky & Seymour Papert (1968)

- O Perceptron é incapaz de classificar corretamente padrões não linearmente separáveis
- A maioria dos problemas são **não linearmente separáveis!**

Perceptrons

Marvin Minsky & Seymour Papert (1968)

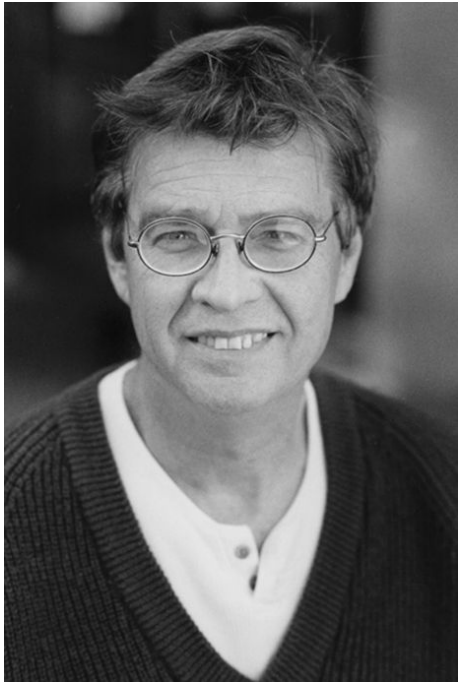
- O Perceptron é incapaz de classificar corretamente padrões não linearmente separáveis
- A maioria dos problemas são **não linearmente separáveis!**
- Se colocar mais uma camada de neurônios é possível contornar esta limitação, mas **como achar os pesos para estes neurônios intermediários**?

Backpropagation

David Rumelhart (1986)

Seppo Linnainmaa propôs a diferenciação automática, caso geral do BP (1970)

Paul Werbos propôs usá-la para treinar redes neurais (1974)



Redes Neurais

Devido à similaridade com a estrutura do cérebro, as Redes Neurais exibem características semelhantes às observadas nos seres vivos, tais como:

Procura paralela e endereçamento pelo conteúdo

- O cérebro não possui endereço de memória e não procura a informação sequencialmente

Aprendizado

- A rede aprende por experiência, não necessitando explicitar os algoritmos para executar uma determinada tarefa

Redes Neurais

Devido à similaridade com a estrutura do cérebro, as Redes Neurais exibem características semelhantes às observadas nos seres vivos, tais como:

Associação

- A rede é capaz de fazer associações entre padrões diferentes
  - Cidade → Pessoa
  - Perfume → Pessoa
  - Pessoa → Nome

Generalização

- Redes Neurais são capazes de generalizar o seu conhecimento a partir de exemplos anteriores
- Habilidade de lidar com ruídos e distorções, respondendo corretamente a padrões novos

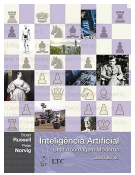
Redes Neurais

Devido à similaridade com a estrutura do cérebro, as Redes Neurais exibem características semelhantes às observadas nos seres vivos, tais como:

Robustez e Degradação Gradual

- A perda de um conjunto de elementos processadores e/ou conexões sinápticas não causa o mau funcionamento da rede neural (exemplo: plasticidade cerebral)

Leia mais sobre este tema...



Russell, S., Norvig, Peter. Inteligência Artificial - Capítulo 18. 2ª Ed. / Capítulo 19. 4ª Ed. Campus-Elsevier; Brasil, 2022.

creative commons

COMMONS DEED

Atribuição-Uso Não-Comercial-Compartilhamento pela Licença 2.5 Brasil

Você pode:

- copiar, distribuir, exibir e executar a obra

- criar obras derivadas

Sob as seguintes condições:

Atribuição — Você deve dar crédito ao autor original, da forma especificada pelo autor ou licenciante.

Uso Não-Comercial — Você não pode utilizar esta obra com finalidades comerciais.

Compartilhamento pela mesma Licença — Se você alterar, transformar, ou criar outra obra com base nesta, você somente poderá distribuir a obra resultante sob uma licença idêntica a esta.

Para ver uma cópia desta licença, visite http://creativecommons.org/licenses/by-nc-sa/2.5/br/ ou mande uma carta para Creative Commons, 171 Second Street, Suite 300, San Francisco, California, 94105, USA.